

DoDr

Medicina com evidência.

Infraestrutura brasileira de IA clínica que só responde o que consegue citar
— modelos abertos, dado em São Paulo, trilha auditável.

Proposta de validação clínica — Hospital Israelita Albert Einstein · São Luiz / Rede D'Or · Notre Dame Intermédica · SulAmérica · CRM-SP

Setembro de 2026 · BeansTech

Em uma tela

O que a BeansTech traz — e o que não traz

6

camadas entre a pergunta e a resposta — nenhuma delas é 'confie no modelo'

9

portais médicos já no ar em ECS São Paulo (dodr.ai, exame.tech, prontuario.tech...)

0

bytes de dado clínico fora do Brasil: recuperação, PII e verificação rodam em SP

4

níveis de modelo, todos de peso aberto (Apache-2.0 / MIT) — trocáveis sem perder o acervo

O que não é

- ▶ Não é diagnóstico autônomo.
- ▶ Não substitui o prontuário.
- ▶ Não usa dado do paciente para treinar.
- ▶ Não responde sem trecho de fonte autorizada.

Por que um chat genérico não serve ao hospital

Três falhas estruturais das APIs de IA generativa no uso clínico

1

Alucina com confiança

Modelos de linguagem completam texto; não sabem o que não sabem. Dose, nome comercial e referência inventados saem com a mesma fluência de um fato.

2

Muda sem avisar

A mesma pergunta, seis meses depois, pode ter outra resposta — o modelo no servidor do fornecedor foi trocado. Pesquisa e protocolo deixam de ser reprodutíveis.

3


Leva o dado embora

Prompt com histórico do paciente atravessa o Atlântico. LGPD art. 11 e o sigilo médico passam a depender de contrato com terceiro estrangeiro.

A resposta da BeansTech não é um modelo melhor. É uma cadeia em que o modelo é a peça menos confiável — e é tratado como tal.

A cadeia anti-alucinação

Seis camadas, em ordem fixa. Sem trecho recuperado, nenhum modelo é chamado.



Resultado: **supported** · **partial** · **insufficient** — a resposta diz o que sustenta, o que falta e de onde veio (documento, revisão, página). Afirmação sem suporte é removida, não suavizada.

Fonte: *healthtech/shared/evidence-chain* (BeansTech, 2026); RAGMED — portal, dados e fluxos §6–9.

O que o médico recebe

Cada afirmação carrega sua prova. Exemplo ilustrativo do contrato de resposta.

Pergunta	Dose pediátrica de dipirona por via oral?
Afirmação	A dose habitual em crianças é 10–15 mg/kg por dose, até 4 vezes ao dia. [1]
Evidência [1]	Bula profissional — Anvisa · registro · revisão sha256:9c1e... · p. 3
Suporte	supported (0,91 — verificador medpubr)
Aplicabilidade	Crianças > 3 meses; não cobre insuficiência renal
Faltou	Peso do paciente para calcular a dose absoluta


Por que isso importa

- ▶ O profissional abre o trecho original, compara versões e vê onde o conhecimento termina.
- ▶ Auditoria: resposta → trechos → documento → revisão. Reprodutível meses depois.
- ▶ A mesma API serve IAs parceiras e sistemas do hospital (OpenAPI, token por tenant).
- ▶ Abstenção é resposta válida: "insufficient" em vez de chute.

Ilustrativo — valores e citação de exemplo; o formato é o do contrato JSON de resposta (RAGMED §9).

Onde cada coisa roda

Dado clínico em São Paulo. Para fora vai texto sem identificação — e só quando há trecho.



Inventário verificado por API na conta Alibaba Cloud em 13–15/09/2026 (ALIBABA-HEALTHTECH-2026-09.md).

Quatro níveis de modelo — todos de peso aberto

Substituíveis sem perder o acervo, o benchmark ou a trilha. Escolha por medição, não por marca.

Nível	Modelo	Licença	Papel	Onde
Rápido	Qwen (Model Studio)	API Alibaba	Síntese com citações; volume	Singapura
Clínico	MedGemma 27B · Granite Guardian	Gemma / Apache-2.0	Revisão clínica; guardrails; PT-BR	Singapura, GPU própria
Multimodal	Lingshu-32B · Lingshu-I-8B	MIT	Imagem médica + texto (candidatos)	Singapura, GPU própria
Excelência	Baichuan-M3-235B (Qwen3-MoE)	Apache-2.0	Casos difíceis; segunda síntese	Virgínia, 4× L20

Embeddings: BGE-M3 (multilíngue) como padrão; MedCPT e Qwen3-Embedding-Medical em avaliação por recall PT → PT e PT → EN.
Regra: modelo entra por benchmark cego com revisão clínica; concordância entre modelos não substitui evidência.

Licenças conferidas nas model cards (Hugging Face) em 15/09/2026. Lingshu e Baichuan-M3 em implantação; desempenho clínico ainda não medido.

Conformidade desde o desenho

Não é um anexo jurídico: são controles já implantados e verificáveis

■ Identidade única

BeansTech ID (Keycloak, OIDC): senha Argon2, TOTP obrigatório para profissional, passkeys; pronto para gov.br e certificado ICP-Brasil; SSO da instituição por SAML/OIDC

■ Dados clínicos

Postgres em SP com arquivamento contínuo cifrado (AES-256): restauração a qualquer ponto no tempo — perda máxima $\approx$ 5 min; ensaio de restauração executado

■ Minimização

PII removida antes de qualquer modelo; treinamento com dado de paciente: nunca por padrão

■ Segredos

KMS 3.0: nenhuma credencial em código ou disco; rotação sem redeploy manual

■ Trilha

Login, acesso, chave de API e cada resposta (trechos, modelo, versão) auditáveis — LGPD art. 37; sigilo profissional (CFM)

■ Resiliência

Snapshots diários, backups sem permissão de exclusão, alarmes 24×7, réplica de GPU por imagem

Estado verificado em 15/09/2026. Adequação regulatória específica (CFM, ANS, CEP/CONEP) é definida com cada instituição no piloto.

Não é conceito: está no ar

Entregas verificáveis em 15 de setembro de 2026

No ar

dodr.ai · app.dodr.ai

exame.tech

prontuario.tech

drogaria.tech

beanshealth.com.br

portaldodontista.ai

drhealth.tech

petiq.tech

id.beanstech.com.br (login)

cms.beanstech.com.br (conteúdo)

3

máquinas GPU próprias (2 em Singapura, 1 em Virgínia) com modelos médicos residentes

12

bancos Postgres + identidade gerenciada, com restauração a ponto no tempo

1

cadeia de evidência compartilhada por todos os portais e pela API para parceiros

Verificação: HTTP 200 nos domínios, inventário de ECS/PolarDB/KMS por API — ALIBABA-HEALTHTECH-2026-09.md §3, §9, §10, §13.

O mesmo motor, cinco usos

O que propomos validar com cada instituição — e o que ela ganha

Instituição	Uso proposto	Ganho esperado	O que validamos juntos
Einstein	Pesquisa clínica reprodutível: modelo, versão e corpus fixados por estudo; benchmark cego PT-BR	Publicação com IA auditável; IP do modelo ajustado fica com o hospital	Erro clínico adjudicado por especialistas; reprodutibilidade em 6 meses
São Luiz / Rede D'Or	Evidência à beira-leito e apoio a laudo com citação (protocolos e bulas vigentes)	Menos tempo de busca; menos variação entre unidades	Tempo por consulta de protocolo; taxa de abstenção correta
Notre Dame Intermédica	Escala em atenção primária: PCDT/SUS e linhas de cuidado padronizadas na rede	Padronização em centenas de unidades; custo por resposta baixo	Aderência a protocolo; custo por resposta aprovada
SulAmérica	Segunda opinião e auditoria de sinistro com evidência citável; API com cota por parceiro	Decisão defensável perante beneficiário e ANS	Concordância com auditor; trilha completa por decisão
CRM-SP	Referência ética: abstenção, sem diagnóstico autônomo, trilha por resposta	Parâmetro público para IA médica no estado	Critérios de transparência e responsabilidade profissional

Propostas de validação; não pressupõem parceria, endosso ou disponibilidade de dados das instituições.

Piloto de 90 dias, com métricas combinadas antes

Uma tarefa definida pela instituição; revisores independentes; relatório de erros e custo ao final

Dias 0–30

Escopo e linha de base

Especialidade e coleção (ex.: PCDT + bulas); 200 perguntas reais anonimizadas; medir como a equipe responde hoje

Dias 30–60

Piloto cego

Respostas do DoDr vs. baseline, revisadas sem saber a origem; casos de abstenção e de atualização de diretriz

Dias 60–90

Relatório e decisão

Erros com impacto clínico adjudicados; recall e fundamentação; tempo poupado; custo por resposta aprovada


Critérios de liberação

- ▶ Fundamentação: fração de afirmações realmente sustentadas pelo trecho citado
- ▶ Clínica: erros graves não resolvidos bloqueiam a promoção — sem exceção
- ▶ Abstenção: nem responder sem evidência, nem recusar quando há suporte
- ▶ Privacidade: zero vazamento entre tenants, logs e cache

Metodologia: RAGMED §11 (dimensões de avaliação e critérios de liberação).

Custo por resposta — e por que a escala muda tudo

Estimativa com a infraestrutura atual; o piloto substitui a estimativa por medição



US\$ 0,03–0,12

custo marginal por resposta com evidência, acima de ~25 mil respostas/mês

O que pesa: a GPU de excelência ($\approx$ US\$ 7 mil/mês) — por isso ela só entra em caso difícil.

O que não pesa: síntese rápida coberta por plano pré-pago; verificação em CPU no Brasil.

Referência de lista: US\$ 0,50 por resposta via API ou R\$ 149/mês por profissional (500 respostas).

Estimativa (ALIBABA-HEALTHTECH-2026-09.md §6.2), custos de infraestrutura da fatura de set/2026. Valores ilustrativos até a medição do piloto.

O que ainda não está provado

Dizer isso agora é parte do método

Modelos novos

Lingshu-32B e Baichuan-M3 estão em implantação; nenhum número de desempenho clínico foi medido ainda.

Coleção inicial

PCDT, bulas Anvisa e SciELO estão em ingestão; cada documento entra com licença, versão e vigência revisadas.

Uso pretendido

Apoio à decisão e consulta a evidência. Não é dispositivo diagnóstico; qualquer uso regulado passa por CEP/CONEP e Anvisa.

Instituições

Nada aqui pressupõe parceria, endosso ou dados de Einstein, Rede D'Or, Notre Dame, SulAmérica ou CRM-SP.

O ativo que fica é o acervo autorizado, o benchmark clínico brasileiro e a trilha — os modelos são trocáveis.

Próximos passos

O que pedimos a cada instituição

- 1 Reunião de 45 min com a equipe clínica e de dados para escolher a tarefa do piloto
- 2 Definição conjunta das métricas e dos limiares de liberação antes de qualquer resposta ser gerada
- 3 200 perguntas reais anonimizadas e dois revisores independentes
- 4 Acordo de confidencialidade e, se aplicável, protocolo ao CEP
- 5 Relatório de 90 dias: erros, abstenções, custo por resposta e recomendação de seguir ou parar

BeansTech

dodr.ai
id.beanstech.com.br
contato@feijaojustech.com.br

Matheus Ximenes